

Multimodal Video Deepfake Detection and Explanation: A Zero-shot Approach via RAG and MLLM Reasoning

Đặt vấn đề và Nhận diện Khoảng trống Nghiên cứu (GAP Analysis)

Sự phát triển của Deepfake đòi hỏi các hệ thống phát hiện không chỉ đưa ra kết quả nhị phân (Thật/Giả) mà còn phải giải thích được nguyên nhân. Qua khảo sát các nghiên cứu SOTA hiện tại, em nhận thấy các khoảng trống (GAPs) lớn:

Hạn chế của hướng tiếp cận EDVD (Explainable Deepfake Video Detection): EDVD-LLaMA giải quyết bài toán giải thích bằng cách kết hợp đặc trưng hình ảnh vào MLLM. Tuy nhiên, hệ thống này bỏ qua hoàn toàn dữ liệu âm thanh (No Audio), làm mất đi lượng lớn thông tin quan trọng. Hơn nữa, phương pháp này yêu cầu huấn luyện lại LLM, dẫn đến chi phí tính toán khổng lồ và khó mở rộng khi có kỹ thuật Deepfake mới.

Hạn chế của hướng tiếp cận Video-RAG: Video-RAG khắc phục được vấn đề tài nguyên bằng pipeline không cần huấn luyện (training-free), kết hợp các công cụ bên ngoài (ASR, OCR, DET) và kỹ thuật RAG để LLM xử lý video dài. Dù vậy, nó chỉ hoạt động trên domain hỏi-đáp chung, không chứa các công cụ pháp y chuyên sâu để bóc tách dấu vết Deepfake.

Hạn chế của hướng tiếp cận Zero-shot: Một số nghiên cứu tính toán sự mâu thuẫn giữa âm thanh và hình ảnh (ví dụ: khoảng cách ngữ nghĩa, đồng bộ thời gian) trên dữ liệu thật (genuine data) để phát hiện Deepfake. Tuy nhiên, chúng chỉ nhả ra một con số kết luận khô khan, hoàn toàn thiếu đi lớp ngôn ngữ để diễn giải cho con người.

Đề xuất giải pháp: Từ các GAPs trên, đề án đề xuất một hệ thống phát hiện và giải thích Deepfake đa phương thức theo kiến trúc không cần huấn luyện (Training-free). Giải pháp vận hành dựa trên một luồng xử lý chặt chẽ: Đầu tiên, hệ thống **trích xuất các đặc trưng pháp y đa phương thức** (Hình ảnh, Âm thanh, Đồng bộ môi, Nhịp tim). Tiếp theo, hệ thống **tự động đánh giá mức độ bất thường** của các chỉ số này so với phân phối dữ liệu của video tự nhiên. Khối dữ liệu sau đó được lưu tạm thời trên RAM (hoặc cơ sở dữ liệu) để **cơ chế RAG truy xuất ra Top các phân đoạn khả nghi nhất**. Cuối cùng, hệ thống nạp trực tiếp manh mối vào LLM thương mại để **thực hiện đối chiếu chéo và tự động sinh ra kết luận giải thích** chi tiết.

System Architecture & Data Pipeline

Hệ thống được thiết kế theo kiến trúc phi trạng thái (Stateless Architecture), đi từ việc phân giải dữ liệu thô đến khi sinh ra các suy luận ngữ nghĩa. Luồng xử lý bao gồm 5 Module nối tiếp nhau:

Module 1: Phân mảnh dữ liệu theo thời gian (Temporal Chunking)

Video đầu vào được giải mã và chia nhỏ theo cấu trúc phân tầng thời gian để tối ưu hóa việc phân tích:

- **Cấp độ Chunk (Ví dụ: 4 giây):** Dùng để xử lý và đồng bộ các đặc trưng mang tính toàn cục như Âm thanh và Khẩu hình.
- **Cấp độ Slide (Ví dụ: 0.5 giây):** Phân mảnh nhỏ hơn bên trong mỗi Chunk để soi chiếu các đặc trưng vi mô liên tục trên từng khung hình.

Module 2: Trích xuất Đặc trưng Đa phương thức (Multimodal Feature Extraction)

Trên mỗi phân đoạn dữ liệu (Chunk/Slide), hệ thống không sử dụng các mô hình End-to-End (hộp đen) mà triển khai 4 cụm thuật toán giám định chuyên sâu chạy song song. Mỗi cụm chịu trách nhiệm bóc tách một lớp tín hiệu vật lý hoặc sinh lý cụ thể, được kế thừa từ các nghiên cứu SOTA:

Trên mỗi phân đoạn dữ liệu, hệ thống triển khai 4 cụm thuật toán (Feature Sets) chạy song song nhằm bóc tách toàn diện các bất thường vật lý, sinh lý và tín hiệu. Các đặc trưng này được thiết kế chi tiết như sau:

1. Bất thường Thị giác và Không gian (Visual & Spatial Anomalies)

- **Phương pháp:** Cụm này tập trung vào các sai lệch ở cấp độ pixel và hình học khuôn mặt, bao gồm:
 - *Facial Landmarks & Kinematics:* Trích xuất tọa độ của mắt, mũi, miệng và theo dõi quỹ đạo di chuyển của chúng qua các frame để tìm kiếm sự rung lắc (Jittering) bất thường.
 - *Blur Variance:* Sử dụng toán tử Laplacian để đo lường và theo dõi mức độ biến thiên độ mờ của vùng mặt giữa các khung hình liên tiếp.
 - *Texture Contrast Smoothness:* Tính toán sự thay đổi độ mịn kết cấu bề mặt da thông qua Ma trận đồng hiện mức xám (GLCM).
 - *Blending Artifacts Intensity:* Đo lường cường độ lỗi ghép biên bằng cách kết hợp mật độ viền (Edge Density thông qua thuật toán Canny) và tỷ lệ phân bố phổ tần số cao/thấp (thông qua biến đổi Fourier rời rạc - DFT).
- **Cơ sở khoa học:** Kế thừa phương pháp phân tích tính toàn vẹn khuôn mặt (Facial Integrity Analysis) từ nghiên cứu EDVD-LLaMA để định lượng hóa các lỗi nội suy của AI sinh tạo.

2. Tính nhất quán Nghe - Nhìn (Audio-Visual Consistency)

- **Phương pháp:** Đo lường sự đồng bộ giữa luồng âm thanh và luồng hình ảnh (khẩu hình) dựa trên 3 hệ thống đánh giá độc lập:
 - *Content Consistency Fake Detection (CCFD):* Đánh giá sự nhất quán về nội dung bằng cách giải mã chuỗi văn bản từ âm thanh (ASR) và từ khẩu hình (VSR), sau đó tính toán khoảng cách chỉnh sửa (Edit distance / WER).
 - *Temporal Consistency Fake Detection (TCFD):* Đánh giá sự nhất quán về mặt thời gian (nhịp điệu phát âm) giữa luồng giọng nói và cử động môi.
 - *Semantic Consistency Fake Detection (SCFD):* Trích xuất các đặc trưng ngữ nghĩa từ cả hai luồng và đo lường độ tương đồng Cosine (Cosine similarity).
- **Cơ sở khoa học:** Ứng dụng trực tiếp khung lý thuyết từ nghiên cứu *Zero-Shot Fake Video Detection by Audio-Visual Consistency*, sử dụng sự mâu thuẫn đa thể thức làm minh chứng phát hiện giả mạo (Zero-shot) mà không cần huấn luyện trên dữ liệu Fake.

3. Tín hiệu Sinh lý và Sinh học (Physiological & Biological Signals)

- **Phương pháp:** Tìm kiếm các tín hiệu sự sống (Liveness) vốn thường bị triệt tiêu trong các video do AI sinh tạo:
 - *Nhịp tim từ xa (rPPG - remote Photoplethysmography):* Đo lường sự biến thiên vi mô của sắc độ da do quá trình bơm máu tuần hoàn.
 - *Blinking Rate & Pupil Micro-movements:* Theo dõi tần số chớp mắt và các vi chuyển động tự nhiên của đồng tử.
 - *Head Pose & Gaze Sync:* Đánh giá tính đồng bộ vật lý giữa hướng xoay của đầu và hướng nhìn của ánh mắt.
- **Cơ sở khoa học:** Các mô hình GAN hay Diffusion thường chỉ tập trung tái tạo kết cấu bề mặt mà không thể mô phỏng chính xác các phản xạ sinh lý học vi mô của con người thực.

4. Bất thường Âm thanh (Acoustic Anomalies)

- **Phương pháp:** Bóc tách các đặc trưng tín hiệu số của luồng Audio để tìm kiếm dấu vết của Vocoder và công nghệ Voice Cloning:
 - *Acoustic Artifacts:* Trích xuất và phân tích các hệ số Mel-frequency cepstral coefficients (MFCCs).
 - *Jitter & Shimmer:* Đo lường các vi sai lệch về tần số cơ bản (Jitter) và sai lệch về biên độ (Shimmer) trong thanh quản, nhằm phát hiện sự cứng nhắc cơ học của giọng nói do AI tổng hợp.
- **Cơ sở khoa học:** Bổ sung mảng phân tích âm thanh chuyên sâu nhằm khắc phục hoàn toàn điểm yếu của các hệ thống giám định hiện tại (như EDVD vốn bỏ qua dữ liệu Audio).

Module 3: Chuẩn hóa Thống kê và Diễn giải Ngữ nghĩa trong JSON (Statistical Standardization & Semantic JSON Mapping)

1. Vấn đề giải quyết (Problem Statement)

Các đặc trưng trích xuất từ Module 2 tồn tại dưới dạng dữ liệu thô (Raw metrics) với các đơn vị đo lường không đồng nhất. Để MLLM có thể suy luận chính xác, hệ thống cần một cơ chế vừa **định lượng** (để máy tính xếp hạng bất thường) vừa **định tính** (để MLLM hiểu ngữ cảnh).

2. Chuẩn hóa Độ lệch Bất thường (Z-score Normalization)

Để tạo ra một thang đo chung cho việc truy xuất (Retrieval), module này áp dụng phương pháp chuẩn hóa Z-score:

- **Thiết lập Baseline:** Hệ thống tính toán Giá trị trung bình (μ) và Độ lệch chuẩn (σ) từ tập dữ liệu video tự nhiên.
- **Tính toán độ lệch:** Chỉ số thô X được quy đổi thành giá trị $Z = \frac{X - \mu}{\sigma}$.

- **Tổng hợp Anomaly Score:** Các giá trị \$\$\$ của 4 phương thức được cộng có trọng số để tạo ra điểm số đại diện cho mức độ khả nghi của cả Chunk, giúp Module 4 lọc ra các đoạn cần giám định.

3. Đóng gói JSON diễn giải đa tầng (Self-Explaining JSON Packaging)

Đây là bước cốt lõi của module. Thay vì chỉ gửi số, hệ thống sử dụng tập luật (Rule-based) để trực tiếp nhúng các đoạn mô tả trạng thái vào cấu trúc dữ liệu JSON. Mỗi "Manh mối pháp y" trong JSON sẽ bao gồm:

- **Value:** Con số thực tế đo được (Raw & Z-score).
- **Interpretation:** Đoạn văn bản mô tả trạng thái dựa trên ngưỡng (Ví dụ: "Mất tín hiệu tuần hoàn mao mạch dưới da", "Khẩu hình lệch nghiêm trọng so với âm thanh").
- **Timestamp:** Mốc thời gian chi tiết của sự cố.
- **Anomaly Score:** Điểm bất thường đại diện cho cả chunk

Module 4: Truy xuất Phi trạng thái và Đóng gói Ngữ cảnh Kép (Stateless Retrieval & Dual-Context Packaging)

1. Vấn đề giải quyết (Problem Statement)

Khi xử lý các video dài (Long-video), việc nạp toàn bộ thời lượng video vào Mô hình Ngôn ngữ Đa phương thức (MLLM) là bất khả thi do giới hạn của cửa sổ ngữ cảnh (Context Window) và chi phí API cực kỳ đắt đỏ. Hệ thống cần một cơ chế lọc nhiễu, chỉ giữ lại những phân đoạn mang tính quyết định nhất và đóng gói chúng dưới định dạng đa phương thức để MLLM dễ dàng tiêu hóa.

2. Truy xuất Bất thường trên Bộ nhớ đệm (In-Memory Anomaly Retrieval)

- Dữ liệu báo cáo trạng thái (JSON) của toàn bộ các Chunk sinh ra từ Module 3 được lưu giữ tạm thời trên bộ nhớ đệm (RAM), hoặc cơ sở dữ liệu, theo kiến trúc phi trạng thái (Stateless).
- Hệ thống áp dụng thuật toán sắp xếp để truy xuất tức thời **Top-K Chunks** sở hữu Điểm Bất thường Tổng hợp cao nhất. Bằng cách này, hệ thống đóng vai trò như một cơ chế "Hard Attention", chủ động bỏ qua các phân đoạn video bình thường và chỉ tập trung vào các giây phút có dấu hiệu lừa đảo.

3. Tự động Cắt Video và Đóng gói Dữ liệu (Auto-clipping & Data Packaging)

Đây là bước bản lề để chuyển giao từ dữ liệu số học sang dữ liệu đa phương thức. Đối với mỗi Chunk nằm trong danh sách Top-K khả nghi:

- **Auto-clipping:** Hệ thống sử dụng thư viện xử lý đa phương tiện (ví dụ: FFmpeg) dựa trên mốc thời gian (Timestamp, ví dụ: \$00:16 - 00:20\$) để tự động trích xuất trực tiếp đoạn video clip đó ra thành một tệp tin vật lý độc lập (.mp4).
- **Dual-Context Packaging:** Hệ thống đóng gói tệp tin video .mp4 này cùng với bản báo cáo JSON tương ứng (bao gồm: Điểm Z-score thô, Tên chỉ số, và Câu văn bản diễn giải trạng thái, các chỉ số thô) thành một **Hồ sơ Giám định Đa phương thức (Multimodal Forensic Payload)**.

Kết thúc Module 4, hệ thống giải phóng toàn bộ dữ liệu dư thừa trên RAM để đảm bảo tối ưu tài nguyên tính toán. Các "Hồ sơ Giám định" của Top-K Chunks lúc này đã sẵn sàng để gửi qua API cho MLLM đối chiếu chéo.

Module 5: Tác tử Suy luận Đa phương thức và Biện luận Pháp y (Multimodal Reasoning & Forensic Argumentation Agent)

1. Vấn đề giải quyết (Problem Statement)

Các mô hình giám định truyền thống thường bị đánh lừa bởi nhiễu môi trường (ví dụ: ánh sáng yếu làm hỏng rPPG, hoặc tiếng ồn làm lệch khẩu hình), dẫn đến tỉ lệ báo động giả (False Positive) cao. Module 5 đóng vai trò là "bộ não" trung tâm, sử dụng năng lực suy luận của MLLM để đối chiếu chéo giữa hình ảnh thực tế và các chỉ số đo đạc, từ đó phát hiện các thủ đoạn Deepfake tinh vi dựa trên sự mất nhất quán đa phương thức thay vì chỉ dựa vào các ngưỡng số liệu đơn lẻ.

2. Thiết kế Prompt chiến lược (Smart Prompt Engineering)

Để MLLM không bị sa đà vào các con số lớn/bé (Rule-based thuần túy), hệ thống sử dụng kỹ thuật **Chain-of-Thought (Suy nghĩ theo chuỗi)** kết hợp với **Cross-Modal Verification**. Prompt được thiết kế để yêu cầu MLLM thực hiện 3 bước tư duy:

- Quan sát Ngữ cảnh:** Nhìn clip MP4 để hiểu điều kiện quay (Ánh sáng, góc mặt, chuyển động).
- Đối chiếu Chỉ số:** Đọc file JSON để thấy các bất thường mà mắt người khó nhận ra.
- Biện luận Cộng hưởng (Core Logic):** Tìm kiếm sự mâu thuẫn vật lý. Nếu một phương thức báo lỗi nhưng phương thức khác lại hoàn hảo, MLLM phải tự đặt câu hỏi về tính logic (Ví dụ: Giọng nói rất khớp nhưng mạch máu dưới da mặt đứng yên).

Kết thúc module 5, ta sẽ có câu trả lời liệu video có phải fake hay không và lời giải thích về những quyết định đó

Tài nguyên và Dự toán Chi phí Thực hiện (Resource & Budget Estimation)

Để triển khai hệ thống **DeepFakeVideo-RAG** theo kiến trúc đã đề xuất, các nguồn lực cần thiết được phân bổ vào hai nhóm chính: Hạ tầng tính toán và Dịch vụ trí tuệ nhân tạo.

Hạ tầng tính toán (Computational Infrastructure)

Do Module 2 (Multimodal Feature Extraction) chứa các thuật toán xử lý thị giác máy tính và âm thanh chuyên sâu (như rPPG, Landmark Tracking), việc sử dụng GPU là bắt buộc để đảm bảo tốc độ trích xuất nhanh và xử lý được các video độ phân giải cao.

- Giải pháp:** Thuê Container GPU trên các nền tảng Cloud (ví dụ: Vast.ai, RunPod, hoặc Google Colab Pro).
- Cấu hình dự kiến:** 01 x NVIDIA RTX 3090 hoặc 4090 (24GB VRAM).
- Mục đích:** Chạy song song 4 sub-modules trích xuất đặc trưng và thực hiện bước Hiệu chuẩn hệ thống (Calibration) trên tập dữ liệu Baseline.

- **Dự toán chi phí:** Khoảng \$0.4 - \$0.7 mỗi giờ. Tổng thời gian thực nghiệm dự kiến 100 giờ \$\approx\$ **1.200.000 VNĐ - 1.800.000 VNĐ.**

Dịch vụ Mô hình Ngôn ngữ Đa phương thức (MLLM API)

Hệ thống sử dụng API thương mại cho Module 5 để thực hiện suy luận và giải thích báo cáo pháp y mà không cần duy trì hạ tầng phần cứng khổng lồ tại địa phương.

- **Dịch vụ:** Google Gemini Pro API hoặc OpenAI GPT API.
- **Mục đích:** Gửi Top-K Chunks (Video + JSON) để nhận về bản biên luận giải thích cuối cùng.
- **Dự toán chi phí:** Tính theo số lượng Token và số phút Video input. Với quy mô đề án tốt nghiệp **test trên các bộ dataset cùng domain** dự kiến chi phí rơi vào khoảng **500.000 VNĐ - 1.000.000 VNĐ.**